

基于 `build_raw_subset.py` 随机下载 10 条 DROID Raw 数据

本文档说明如何使用现有脚本 `/root/autodl-tmp/build_raw_subset.py`，从官方 `droid_raw` 数据集中随机下载 10 条 episode 到本地，并使用在线hdf5可视化工具查看轨迹文件。

1. 脚本会下载什么

`build_raw_subset.py` 默认从下面的官方 GCS 路径读取数据：

```
gs://gresearch/robotics/droid_raw/1.0.1
```

对于每条随机选中的 episode，脚本会下载：

- `trajectory.h5`
- episode 顶层的 `*.json`
- `recordings/MP4/*.mp4`
- 不下载 `*-stereo.mp4`

下载后会保留官方目录结构，例如：

```
/root/autodl-fs/datasets/droid/droid_raw_10/  
└─ 1.0.1/  
    └─ <lab>/  
        └─ <status>/  
            └─ <date>/  
                └─ <episode>/  
                    ├── trajectory.h5  
                    ├── *.json  
                    └─ recordings/  
                        └─ MP4/  
                            └─ *.mp4
```

2. 环境配置与下载前检查

推荐方式：用 pip 安装 gsutil

在当前 Conda / Python 环境里执行：

```
pip install -i https://pypi.tuna.tsinghua.edu.cn/simple -U gsutil  
不使用清华源也可  
pip install -U gsutil
```

安装完成后重新检查：

```
gsutil version
```

如果能看到 `gsutil` 路径和版本号，说明安装成功。

然后测试是否能访问 DROID raw 的公开 bucket：

```
gsutil ls gs://gresearch/robotics/droid_raw/1.0.1/
```

如果能列出若干目录，就可以继续执行第 3 节的随机下载命令。

3. 随机下载 10 条数据

环境配置完成后，再运行下面的加速下载命令。

如果你当前已经在跑旧命令，而且终端一直停在 `LIST ... -> episodes`，可以先按 `Ctrl+C` 停止，然后改用下面这个命令：

```
python .\build_raw_subset.py \
  --target-episodes 10 \
  --output-root .droid_raw_10 \
  --max-gb 50 \
  --seed 239 \
  --workers 4 \
  --labs AUTOLab \
  --statuses success \
  --max-dates-per-status 1 \
  --max-episodes-per-date 30 \
  --episode-list-output .\droid_raw_10_candidates.txt \
  --downloaded-list-output .\droid_raw_10_downloaded.txt
```

这个命令不会扫描完整 `droid_raw`，而是只在 `AUTOLab/success` 的 1 个日期目录里取最多 30 条候选 episode，再随机打乱并下载 10 条。`--workers 4` 会同时处理 4 条 episode，通常比单线程快很多。

如果网络或磁盘压力太大，可以把 `--workers 4` 改成 `--workers 2`。

参数含义：

- `--target-episodes 10`：只下载 10 条 episode。
- `--output-root`：本地保存目录。
- `--max-gb 50`：最多使用 50GB 空间，防止误下载太多。
- `--seed 239`：随机种子。脚本会用这个种子打乱 episode 顺序。
- `--workers 4`：并发下载 4 条 episode，比单线程快。网络不稳定时可以改成 2。
- `--labs AUTOLab`：只从 `AUTOLab` 这个实验室目录里找候选 episode，用来减少远程枚举时间。
- `--statuses success`：只下载成功 episode，减少候选目录数量。
- `--max-dates-per-status 1`：每种状态最多只看 1 个日期目录。
- `--max-episodes-per-date 30`：每个日期目录最多只取 30 条候选 episode。
- `--episode-list-output`：保存随机打乱后的候选 episode 列表。
- `--downloaded-list-output`：保存成功下载的 episode 列表。

4. 如何换一批随机数据

如果想重新随机一批 10 条数据，只需要换一个 `--seed`：

```
python /root/autodl-tmp/build_raw_subset.py \
--target-episodes 10 \
--output-root .droid_raw_10_seed_42 \
--max-gb 50 \
--seed 42 \
--workers 4 \
--episode-list-output ./droid_raw_10_seed_42_candidates.txt \
--downloaded-list-output ./droid_raw_10_seed_42_downloaded.txt
```


注意：如果 `--seed` 不变，并且候选列表没有变化，那么随机顺序也会保持一致，方便复现实验。

5. 下载中断后如何继续

如果下载过程被中断，可以用之前保存的 `downloaded` 列表排除已经下载过的数据：

```
python /root/autodl-tmp/build_raw_subset.py \
--target-episodes 10 \
--output-root /root/autodl-fs/datasets/droid/droid_raw_10 \
--max-gb 50 \
--seed 239 \
--workers 4 \
--existing-list ./droid_raw_10_downloaded.txt \
--episode-list-output ./droid_raw_10_candidates_resume.txt \
--downloaded-list-output ./droid_raw_10_downloaded_resume.txt
```

脚本内部使用 `gsutil cp -n`，因此已存在的文件不会被重复覆盖。



6. 查看数据结构

图中可以看到AUTOLab贡献的数据集，其中分为正样本（success）和负样本（failure）两部分，每一个日期下面包含三个视角的视频.mp4文件以及.h5格式的轨迹文件

我们可以查看recording中的视频观察三个视角的摆放位置。

打开网址[Online HDF viewer](https://hdf5viewer.org/)将hdf5格式文件拖入可以查看轨迹构成

📄 trajectory.h5

▼ action

- 🔗 cartesian_position
- 🔗 cartesian_velocity
- 🔗 gripper_position
- 🔗 gripper_velocity
- 🔗 joint_position
- 🔗 joint_velocity
- robot_state
- 🔗 target_cartesian_position
- 🔗 target_gripper_position

▼ observation

- camera_extrinsics
- camera_type
- controller_info
- robot_state
- timestamp

字段	含义	作用
action/cartesian_position	末端执行器当前位姿	记录机械臂末端（手爪）当前位置和姿态。
action/cartesian_velocity	末端执行器速度	记录机械臂末端的运动速度。
action/gripper_position	夹爪位置	记录夹爪当前开合状态。
action/gripper_velocity	夹爪速度	记录夹爪开合速度。
action/joint_position	各关节角度	记录机器人各个关节的当前位置。
action/joint_velocity	各关节速度	记录机器人各个关节的运动速度。
action/robot_state	机器人控制状态	保存机器人控制相关的状态信息（不同机器人内容略有不同）。
action/target_cartesian_position	目标末端位姿	控制器希望机械臂下一步到达的末端位置和姿态。
action/target_gripper_position	目标夹爪位置	控制器希望夹爪达到的目标开合状态。
observation/camera_extrinsics	相机外参	描述相机相对于机器人坐标系的位置和姿态。

字段	含义	作用
observation/camera_type	相机类型	记录每个相机的型号或类别。
observation/controller_info	控制器信息	保存采集过程中控制器的配置和运行信息。
observation/robot_state	机器人观测状态	记录机器人实际观测到的状态信息（如关节、末端等）。
observation/timestamp	时间戳	记录每一帧数据的采集时间，用于多模态数据同步。

7.查看RLDS格式的libero仿真数据集

进入libero文件夹

安装环境

```
python -m pip install -i https://pypi.tuna.tsinghua.edu.cn/simple tensorflow tensorflow-datasets matplotlib numpy
不使用清华源也可
python -m pip install tensorflow tensorflow-datasets matplotlib numpy
```

```
python viewer.py --data spatial
```

也可将spatial替换成object goal 10来切换内容

启动后：

快捷键：空格暂停/继续，左右键或 **A/D** 切帧， **N/P** 切 episode， **Q/Esc** 退出。